Лекция 1

Введение в конструирование компиляторов

§1. Компиляторы и интерпретаторы: основные определения

Определение. *Компилятор* (compiler) из языка S в язык T – это программа, осуществляющая перевод программ с языка S на язык T. При этом:
S – *исходный язык* (source language);
T – *целевой язык* (target language, object language);
язык H, на котором написан компилятор, – *язык реализации* (implementation language, host language).

Мы будем использовать запись $S \underset{H}{\rightarrow} T$ для обозначения компилятора из языка S в язык T, написанного на языке H.

Транслятор (translator) – синоним компилятора.

Определение. *Интерпретатор* (interpreter) для некоторого языка L – это программа, осуществляющая выполнение программ, написанных на языке L.

Компиляторы и интерпретаторы близки по структуре.

Компилятор из A в B можно считать интерпретатором языка A' такого, что синтаксис A' совпадает с синтаксисом A, а смысл программы p, написанной на A', заключается в порождении программы на языке B, вычисляющей ту же функцию, что и программа p, если понимать её написанной на языке A.

§2. Т-диаграммы

Т-диаграммы позволяют визуализировать те взаимодействия программ, в которые вовлечены компиляторы и интерпретаторы.

Программа p на языке L:

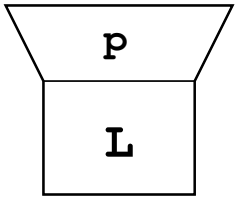

Машина, выполняющая язык M:

Пример:

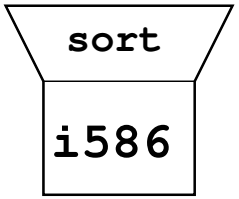

Пример:

Для того чтобы выполнить программу на некоторой машине, язык, на котором написана программа, должен совпадать с языком, который понимает машина.

Выполнение программы p:

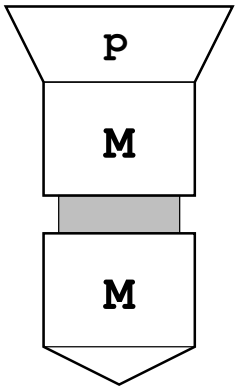

Пример:

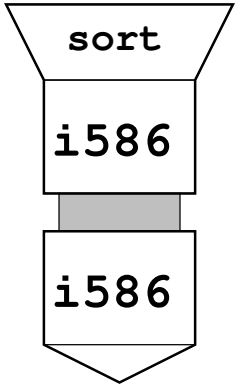

Интерпретатор языка L, написанный на языке M:

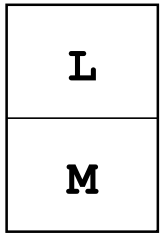

Пример:

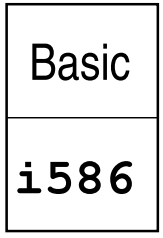

Пример (виртуальная p-машина):

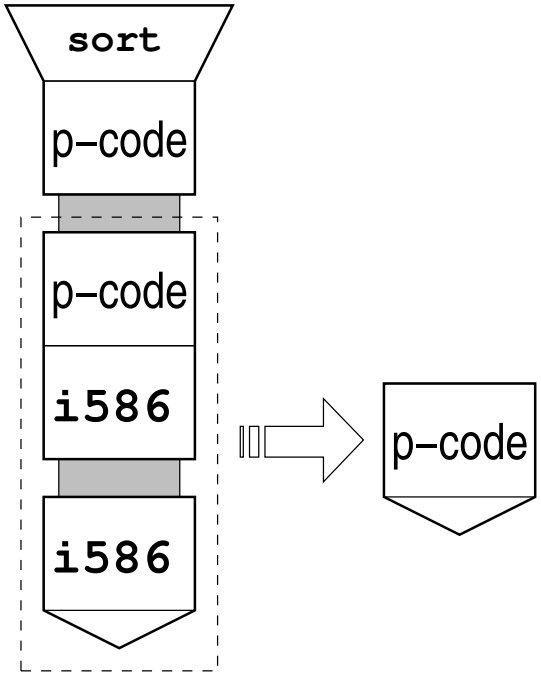

Определение. *Виртуальная машина* для языка L – это сочетание интерпретатора языка L, написанного на языке M, и машины, выполняющей язык M.

Компилятор $S \underset{M}{\rightarrow} T$:

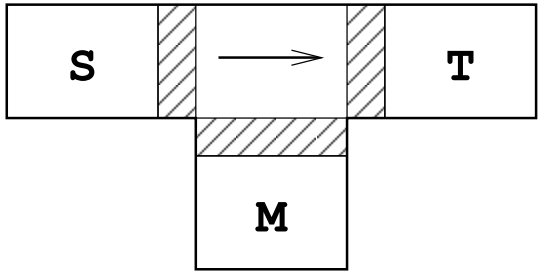

Пример:

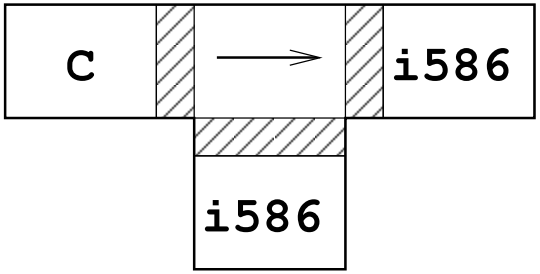

Компилятор $S \underset{M}{\rightarrow} T$, будучи запущен на машине, выполняющей язык M, переводит программы с языка S на язык T.

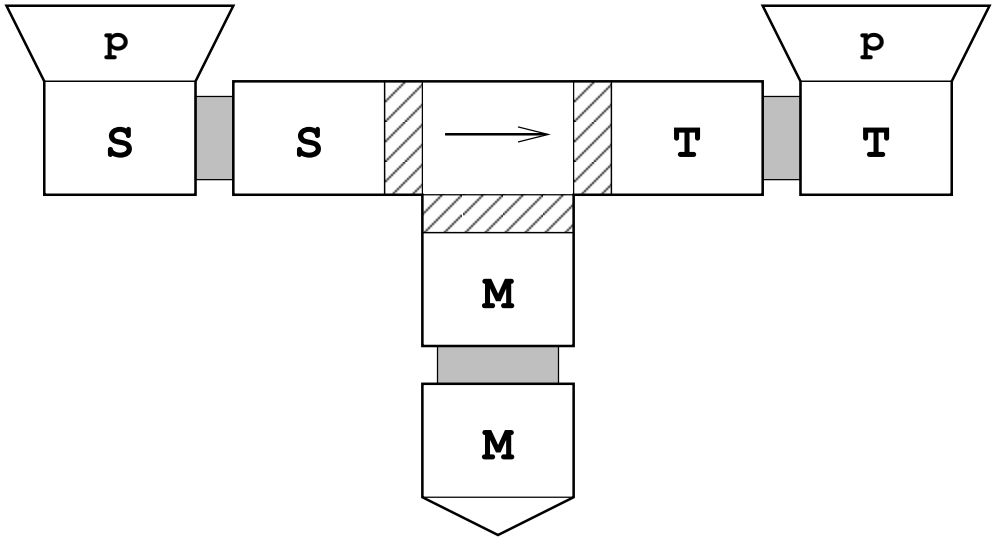

§3. Самоприменимые компиляторы: раскрутка и перенос

Определение. Компилятор $S \underset{S}{\rightarrow} T$ называется *самоприменимым* (self-applicable).

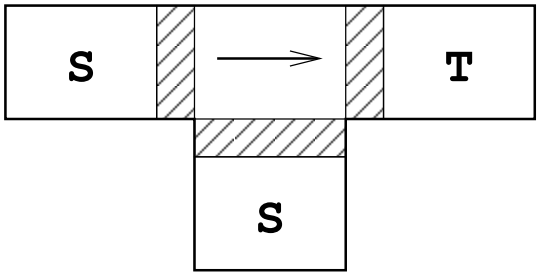

Если для языка S не существует другого компилятора или интерпретатора, то запуск самоприменимого компилятора является непростым делом.

Определение. *Раскрутка* (bootstrapping) – это итерационный процесс создания самоприменимого компилятора $S \underset{S}{\rightarrow} T$, используемый в случае, если есть возможность запуска программ на языке T, а для программ на языке S такой возможности нет.

На каждом шаге раскрутки получается компилятор $S_i \underset{T}{\rightarrow} T$ для всё большего и большего подмножества S_i языка S.

Шаг 1.

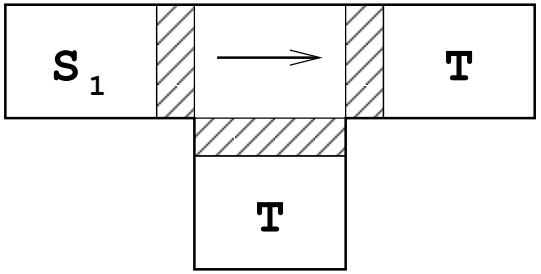

Шаг n.

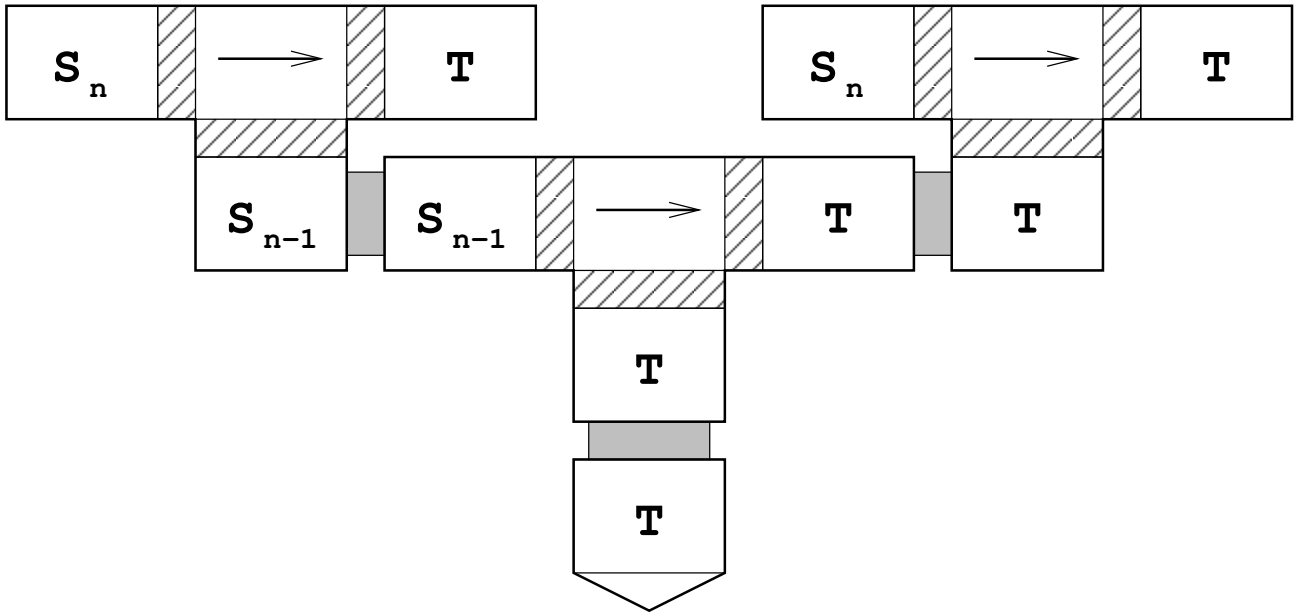

$S_1 \subset \ldots \subset S_{n-1} \subset S_n \subset S$

Определение. *Раскрученный самоприменимый компилятор* языка S на платформе T – это пара компиляторов $\left(S \underset{S}{\to} T,\ S \underset{T}{\to} T\right)$ такая, что применение компилятора $S \underset{T}{\to} T$ к компилятору $S \underset{S}{\to} T$ даёт $S \underset{T}{\to} T$.

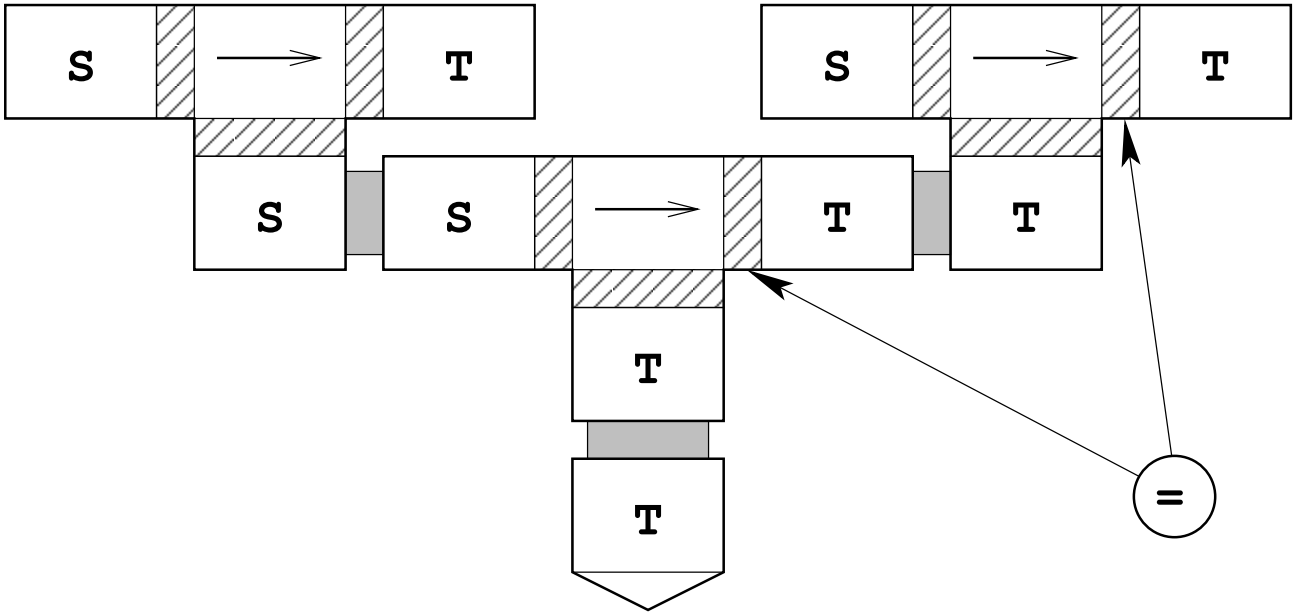

Для переноса раскрученного самоприменимого компилятора

$$\left(S \underset{S}{\rightarrow} T_1,\ S \underset{T_1}{\rightarrow} T_1\right)$$

на платформу T_2 достаточно на основе $S \underset{S}{\rightarrow} T_1$ разработать $S \underset{S}{\rightarrow} T_2$, а затем выполнить два шага:

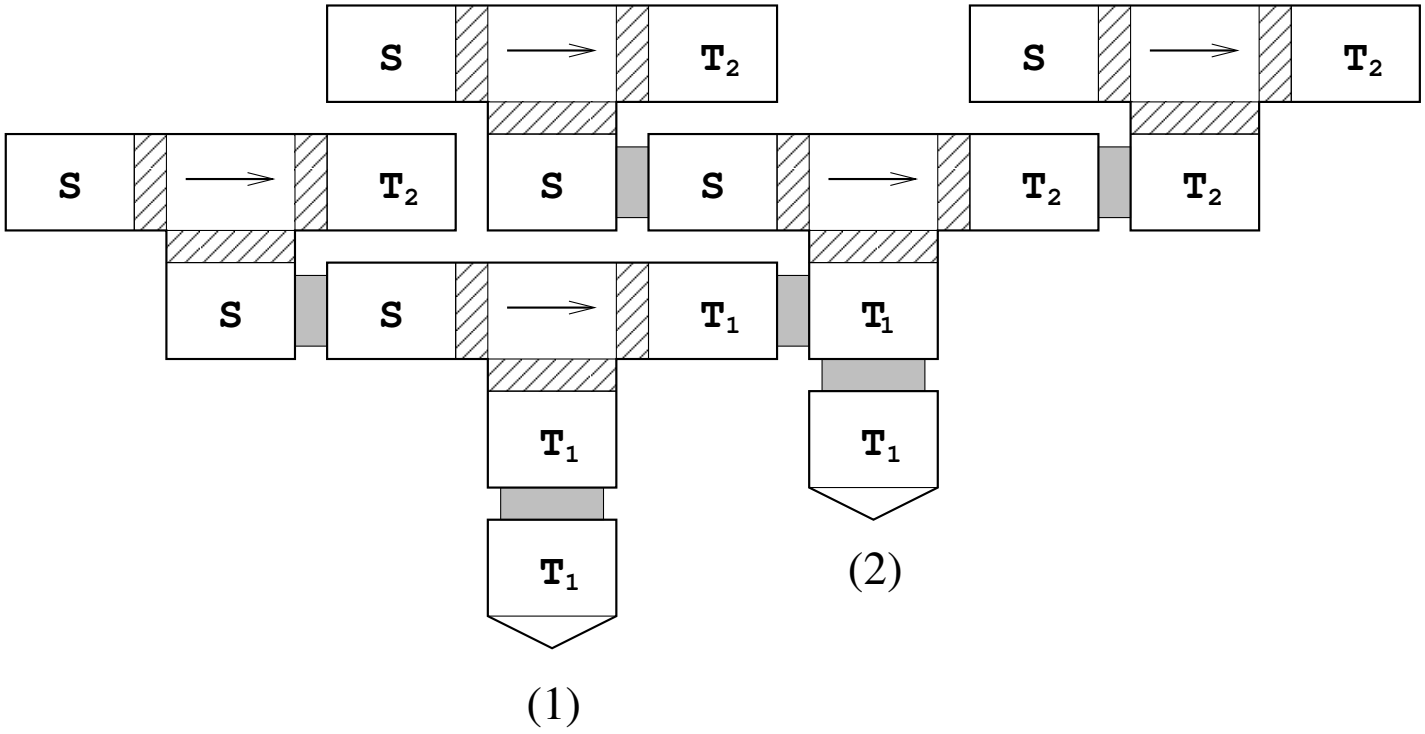

Компилятор $S \underset{T_1}{\rightarrow} T_2$ называется *кросскомпилятором*.

§4. Внедрение «троянских коней» с помощью самоприменимых компиляторов

По статье:
Ken Thompson. *Reflections on Trusting Trust* // Communications of the ACM. Vol. 27, №8. August 1984.

В статье рассматривается раскрученный самоприменимый компилятор языка C:

$$\left(\mathbf{C} \underset{\mathbf{C}}{\rightarrow} \mathbf{Asm},\ \mathbf{C} \underset{\mathbf{Asm}}{\rightarrow} \mathbf{Asm}\right)$$

«Идеализированный» фрагмент компилятора C $\underset{C}{\rightarrow}$ Asm, обрабатывающий Escape-последовательности:

```
c = next();
if (c != '\\')
    return c;

c = next();
switch (c)
{
case '\\': return '\\';
case 'n':  return '\n';
}
```

Попробуем добавить в $C \underset{C}{\rightarrow} Asm$ последовательность \t:

```
c = next();
if (c != '\\')
    return c;

c = next();
switch (c)
{
case '\\': return '\\';
case 'n':  return '\n';
case 't':  return 9;
}
```

В результате получим компилятор $C' \underset{C}{\rightarrow} Asm$.

Выполняем раскрутку:

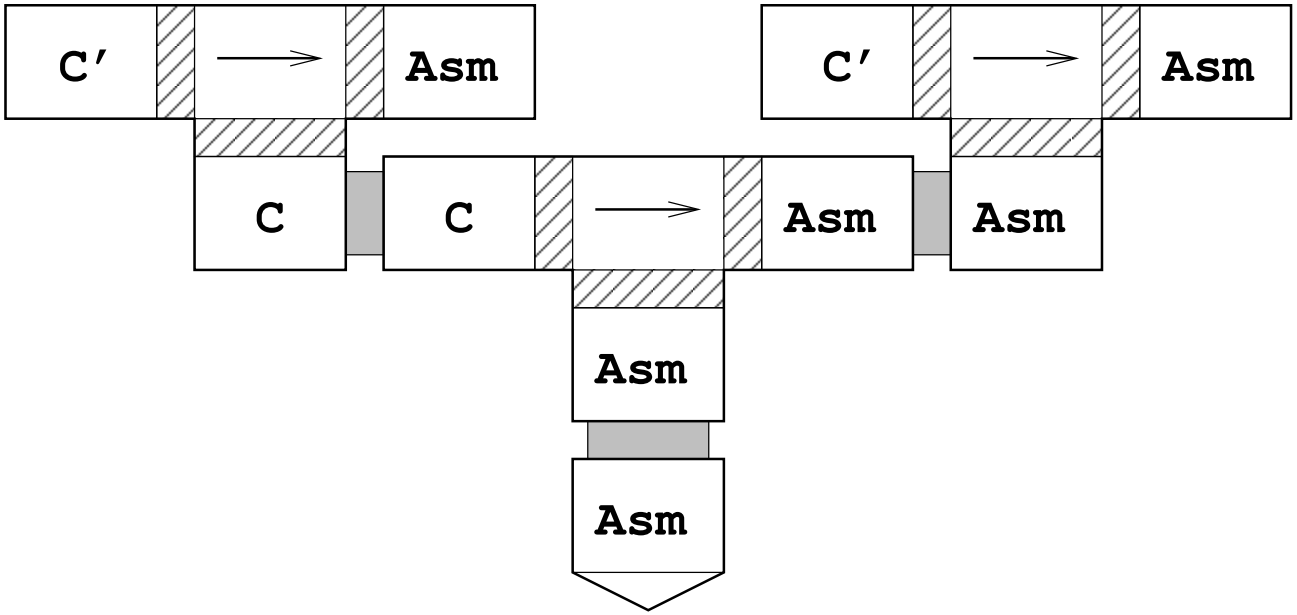

Теперь мы можем «переписать» $C' \underset{C}{\rightarrow} \text{Asm}$ на C':

```
c = next();
if (c != '\\')
    return c;

c = next();
switch (c)
{
case '\\': return '\\';
case 'n':  return '\n';
case 't':  return '\t';
}
```

В результате получим самоприменимый компилятор $C' \underset{C'}{\rightarrow} \text{Asm}$, в тексте которого отсутствует ASCII-код символа '\t'. Дело в том, что этот ASCII-код «ушёл» в $C' \underset{\text{Asm}}{\rightarrow} \text{Asm}$!

Используем раскрутку для внедрения «трояна». Для этого рассмотрим функцию compile() нашего гипотетического компилятора $C \xrightarrow[C]{} Asm$:

```
void compile(char *prog)
{
    ...
    /* Компиляция. */
    ...
}
```

Модифицируем код функции:

```
void compile(char *prog)
{
    if (match(prog,LOGIN_TEXT))
        prog = "...заражённый login...";
    else if (match(prog,CC_TEXT))
    {
        ...
        /* Внедрение заразы в текст компилятора. */
        ...
    }
    ...
    /* Компиляция. */
    ...
}
```

Получаем компилятор $C^{\star} \underset{C}{\rightarrow} Asm$, подменяющий текст программы login и «заражающий» текст компилятора $C \underset{C}{\rightarrow} Asm$.

Выполняем раскрутку:

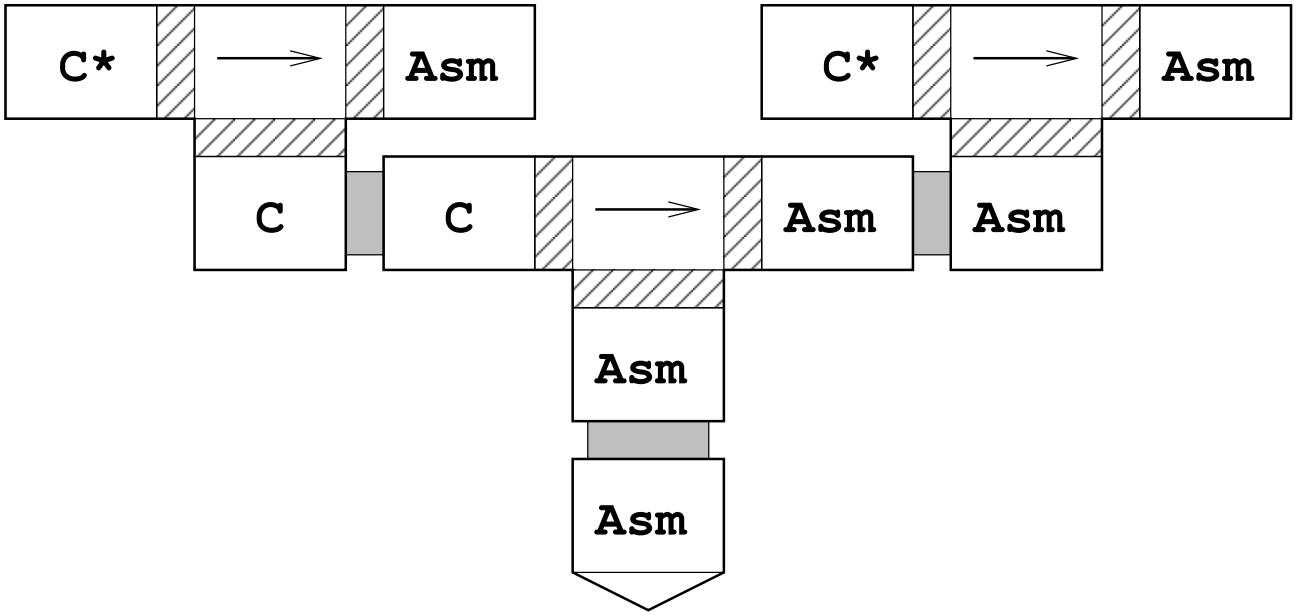

Выдаём пару $\left(\mathrm{C} \underset{\mathrm{C}}{\to} \mathrm{Asm},\ \mathrm{C}^{\star} \underset{\mathrm{Asm}}{\to} \mathrm{Asm}\right)$ за раскрученный самоприменимый компилятор языка C.

Никто не заметит подвоха, так как:

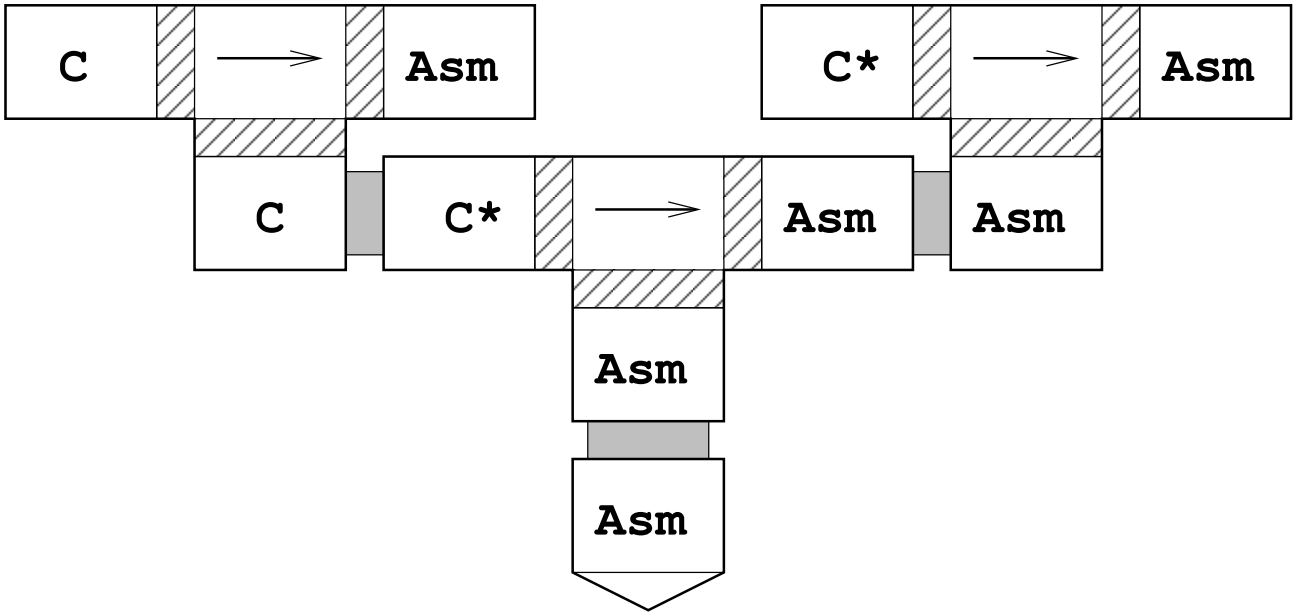

Дополнение. Программа на C, печатающая свой текст.

```
char *s = "\";\n\nint main()\n{\n    ...";

int main()
{
    int i;
    printf("char *s = \"");
    for (i = 0; s[i]; i++)
        switch (s[i])
        {
        case '\n': printf("\\n"); break;
        case '\'': printf("\\\'"); break;
        case '\"': printf("\\\""); break;
        case '\\': printf("\\\\"); break;
        default:   printf("%c", s[i]);
        }
    printf(s);
    return 0;
}
```